

Miniproyecto (CORPUS HOMO-LAT25)

Curso: Procesamiento de Lenguaje Natural

Integrantes: Felipe Martínez / Benjamín Zamorano

1. Síntesis de Decisiones Clave y Hallazgos

¿Qué decisiones tomaron y por qué?

- Se construyó un baseline tradicional con TF-IDF usando n-gramas (1,2) y Regresión Logística. Esta configuración permite capturar palabras individuales y combinaciones cortas relevantes para la polaridad. Debido al desbalance del corpus, donde la clase NEU concentra el 55.04% del entrenamiento, se utilizó `class_weight='balanced'` para reducir el sesgo hacia la clase mayoritaria.
- Como modelo principal se eligió `dccuchile/bert-base-spanish-wwm-cased` (BETO), ajustado mediante fine-tuning supervisado. La elección se justificó porque BETO fue preentrenado en español y puede capturar mejor contexto, negación, ironía y variación dialectal que un modelo basado solo en conteo léxico.
- También se fijó `MAX_LENGTH_DECISION = 262`, ya que el EDA mostró que ese valor corresponde aproximadamente al percentil 95 de longitudes del corpus. Esto permite reducir el truncamiento de textos largos y conservar más contexto semántico, aunque con mayor costo computacional que usar 128 tokens.

¿Qué descubrieron que no esperaban?

El hallazgo principal fue que el baseline clásico cometía muchas confusiones `NEU → NEG` y `NEG → NEU`. En particular, términos de dominio como “trans” o “ley” podían llevar al modelo TF-IDF a clasificar textos informativos como negativos. También se observó que el modelo clásico no detecta bien hostilidad expresada mediante sarcasmo, modismos o referencias locales, porque depende de asociaciones léxicas superficiales y no del contexto completo.

2. Tabla Comparativa de Modelos Propuestos

Los modelos se evaluaron con F1-Macro sobre el split oficial de evaluación (`df_dev`):

Modelo	Configuración Clave	Métrica principal (F1-Macro en split de evaluación / <code>df_dev</code>)	Observación y Análisis del Gap

Baseline Trivial (Zero Rule)	Asignación estática de la clase mayoritaria (NEU) a todas las instancias..	0.2540	Línea de base mínima: Representa el piso absoluto del experimento. Ignora la semántica y absorbe el desbalance del dataset.
Baseline Tradicional (TF-IDF + LR)	N-gramas (1,2), escalado sublineal de frecuencias, class_weight='balanced', semilla 42.	0.4072	Ganancia vs Trivial: +0.1449. Captura palabras clave explícitas, pero sufre ante la ironía y genera falsos positivos por solapamiento léxico.
Modelo Principal (Fine-Tuning BETO)	Arquitectura BERT en español, 3 épocas, tasa de aprendizaje 2e-5, max_length=262.	0.4397	Rendimiento Máximo Real: Mitigó la brecha meta-clásica logrando un incremento neto de +0.0408. La atención bidireccional resolvió ambigüedades de contexto sin truncar textos largos.

Nota: No se pudo cumplir el F1 esperado de 0.7500.

Conclusión: BETO obtuvo el mejor rendimiento real, pero la mejora sobre TF-IDF + LR fue moderada. Para una solución rápida, barata e interpretable, el baseline tradicional es una alternativa razonable. Para producción, se recomendaría BETO solo si el sistema debe enfrentar ironía, ambigüedad, modismos y textos largos; aun así, requeriría más datos, calibración y monitoreo de errores antes de desplegarse.

3. Declaración de Uso de IA

Se utilizó IA como apoyo técnico y de redacción. La herramienta principal fue Gemini, usada para orientar celdas de código, depuración, visualizaciones, estructura del notebook e interpretación de resultados. En la etapa final se utilizó ChatGPT para corroborar consistencia, revisar cumplimiento de la pauta, ajustar redacción y validar decisiones como MAX_LENGTH_DECISION = 262.

El equipo ejecutó y validó el notebook en Google Colab, revisó manualmente los resultados, seleccionó las decisiones finales, interpretó métricas y errores, y ajustó el contenido final. La IA no fue usada para fabricar resultados ni alterar métricas. El equipo puede defender el código y las decisiones incluidas.